

R For Data Science Cheat Sheet

Data Processing

EasyCharts团队-张杰出品

数据的基本类型



- ①数值型(numeric): `a<-1, is.numeric(a)`
- ②字符型(character): `b<- "peter"; nchar(b) #字符串的长度`
- ③日期型(Date): 最常用的是Date (仅储存日期) 和POSIXct (储存日期与时间)
`c<-as.Date("2012-06-12"); class(c)`
`d<-as.POSIXct("2012-06-12 17:32"); class(d)`
- ④逻辑型(logical): `e<-TRUE, f<-FALSE`

常见的数据结构



常见的数据结构包括：向量(vector), 数据框(data.frame), 矩阵(matrix), 列表(list) 和数值(array)

向量(vector)



- 1. 向量(vector)的创建 (# c代表合并 (combine))

输入	输出	描述
<code>c(2,4,6)</code>	2 4 6	将元素连接成向量
<code>2:6</code>	2 3 4 5 6	等差整数数列
<code>seq(2, 3, by=0.5)</code>	2.0 2.5 3.0	步长为0.5的等差数列
<code>rep(1:2, times=3)</code>	1 2 1 2 1 2	将一个向量重复3次
<code>rep(1:2, each=3)</code>	1 1 1 2 2 2	将一个向量中的每个元素重复3次
<code>rnorm(3, mean = 0, sd = 3)</code>	-2.09 -3.52 -4.25	均值为0, 标准差为3的正态分布
<code>runif(3, min = 0, max = 1)</code>	0.63 0.05 0.61	最大值为1, 最小值为0的均匀分布
<code>sample(c("A","B","C"), 4, replace=TRUE)</code>	"A" "A" "A" "B"	从一个向量中随机抽取

- 2. 向量(vector)的处理

- 向量的排序
`Vec<-c(1,4,3,5,2)`
`order<-sort(Vec, index.return=TRUE,decreasing = TRUE)`

- 向量的逆序
`Vec<-c(1,4,3,5,2)`
`Rev<-rev(Vec)`

- 向量的唯一值
`Vec<-c(4,4,5,5,2)`
`Uni<-unique(Vec)`

- 连续向量的离散化
`Num_Vector<- ceiling(runif(10,1,10))`
`Cut_Vector<-cut(Num_Vector,breaks=c(0,3,6,9,11), labels=c("0~3", "3~6", "6~9", ">9"), right = TRUE)`

- (3) 因子向量(factor vector)
 - 普通向量默认的Levels根据字母顺序排序: (Fair,Good, Ideal, Premium, Very Good)
`Cut<-c("Fair","Good","Very Good","Premium","Ideal")`
`Cut_Facor1<-as.factor(Cut)`
 - 更改因子向量的 levels 为 ("Good","Fair","Very Good","Ideal","Premium")
`Cut_Facor2<-factor(x=c("Fair","Good","Very Good","Premium","Ideal"), levels= c("Good","Fair","Very Good","Ideal","Premium"), ordered=TRUE)`
 - 数值型因子向量的类型变换
`Num_Facor<-factor(x=c(1,3,5,2), levels= c(5,3,2,1), ordered=TRUE)`
`Num_Vector1<-as.numeric(as.character(Num_Facor)) # 输出: 1 3 5 2`
`Num_Vector2<-as.numeric(Num_Facor) # 输出: 4 2 1 3`

- (4)向量的选择
`x<-c(1,4,3,5,2)`
 - 选择某个或多个元素: `x[2]; x[-2]; x[2:4]; x[c(1,4)]`
 - 逻辑运算选择元素: `x[x>2]; x[x==1]; x[x<=5]`

数据框(data.frame)



- (1) 数据框的基本信息

`df<-data.frame(x= c("a","b","c"), y=1:3,z=c(2,5,3))`

x	y	z
a	1	2
b	2	5
c	3	3

- 数据框数据的选取
选取某一列: `df[,2]`, `df$y`, `df[[2]]`

x	y	z
a	1	2
b	2	5
c	3	3

选取多列: `df[c("x","y")]`, `df[,1:2]`

x	y	z
a	1	2
b	2	5
c	3	3

选取某一行: `df[2,]`

- 获取数据框的行数、列数和维数:
`nrow()`, `ncol()`, `dim()`

x	y	z
a	1	2
b	2	5
c	3	3

选取多行: `df[1:2,]`

- 获取数据框的列名或行名:
`names()`, `rownames()`, `colnames()`
重新定义列名`names(df)<-c("X", "Y", "Z")`

x	y	z
a	1	2
b	2	5
c	3	3

选取某个元素: `df[2,2]`

- 观察数据框的内容:
`view(df)`, `head(df, n=3)`, `tail(df)`

x	y	z
a	1	2
b	2	5
c	3	3

- (2) 空数据框的创建:

- 创建一个名为Df_Empty, 包括两个变量 (var_a为numeric类型; var_b为character类型) 的data.frame。但是注意: 要加上`stringsAsFactors=FALSE`, 否则在后面逐行输入数据的时候, 会因为var_b的取值未经定义的factor level而报错。
`Df_Empty1<- data.frame(var_a = numeric(), var_b = character(), stringsAsFactors=FALSE)`
- 使用矩阵matrix创建空的数据框
`Df_Empty2 <- data.frame(matrix(ncol = 2, nrow = 0))`
`colnames(Df_Empty2)<- c("var_a","var_b")`

数据的导入导出



- (1) csv格式数据的导入与导出

- 使用`read.csv()`函数, 可以读入数据, 并为data.frame格式存储
`mydata<-read.csv("Data.csv",sep="," ,na.strings="NA", stringsAsFactors=FALSE)`
- 使用`write.csv()`函数, 可以将data.frame的数据存储为csv文件
`write.csv(mydata,file = "File.csv")`

- (2) txt格式数据的导入与导出

- 使用`read.table()`函数可以读入数据, 并为data.frame格式存储
`mydata<-read.table("Data.txt",header = TRUE)`
- 使用`write.table()`函数可以将data.frame的数据存储为csv文件
`write.table(mydata, file = "File.txt")`

- (3) excel格式数据的导入

- 使用`readxl`包的`read_excel()`函数可以读入数据
`mydata<- readxl::read_excel("Data.xlsx", sheet = "Sheet Name")`

- 缺失数据使用NA表示, `is.na()`函数判定
- 空白数据使用NULL表示, `is.null()`函数判定

表格的变换与排序



(2) 变量的转换，根据原有数据框大的列，计算添加新的列：

- dat1<-transform(df_melt, value2=value*2)
- dat2<- transform(df_melt, value2=ifelse(year=="2011", value*2, value))
- dat2<- dplyr::mutate(df_melt, value2=ifelse(year=="2011", value*2, value))

dat1

X	year	value	value2
A	2010	1	2
B	2010	3	6
C	2010	4	8
A	2011	3	6
B	2011	5	10
C	2011	2	4

dat2

X	year	value	Value2
A	2010	1	1
B	2010	3	3
C	2010	4	4
A	2011	3	6
B	2011	5	10
C	2011	2	4

(3)表格的排序：根据数据框的某列数值对整个表排序

- dat_arrange1<- dplyr:: arrange (df_melt, value)
- dat_arrange2<- dplyr:: arrange (df_melt, desc(value))

dat_arrange1

X	year	Value
A	2010	1
C	2011	2
B	2010	3
A	2011	3
C	2010	4
B	2011	5

dat_arrange2

X	year	Value
B	2011	5
C	2010	4
A	2011	3
B	2010	3
C	2011	2
A	2010	1

表格的分组操作



```
df<- data.frame(x=c('A','B','C','A','C'),'2010'=c(1,3,4,4,3),
                '2011'=c(3,5,2,8,9), check.names=FALSE)
df_melt<- reshape2::melt(df, id.vars='x',
                        variable.name="year",value.name = "value")
```

X	2010	2011	Sum
A	1	3	4
B	3	5	8
C	4	2	6
A	4	8	12
C	3	9	12

X	year	Value
A	2010	1
B	2010	3
C	2010	4
A	2010	4
C	2010	3
A	2011	3
B	2011	5
C	2011	2
A	2011	8
C	2011	9

(1) 分行row或列column操作，
可以使用apply()函数按行或列求和：
df_rowsum<- apply(df[,2:3],1,sum)
df_colsum<- apply(df[,2:3],2,sum)

(2)分组group操作数据

只根据year分组操作

- df_group1<- aggregate(value~year,df_melt,mean)
- df_group1<-df_melt %>% dplyr::group_by(year) %>%
dplyr::summarise(avg = mean(value))

先分组group_by(year)

X	year	Value
A	2010	1
B	2010	3
C	2010	4
A	2010	4
C	2010	3
A	2011	3
B	2011	5
C	2011	2
A	2011	8
C	2011	9

后计算df_group1

year	avg
2010	3.0
2011	5.4

同时根据year和x两个变量分组操作

- df_group2<- aggregate(value~year+x,df_melt,mean)
- df_group2<-df_melt %>% dplyr::group_by(year,x) %>%
dplyr::summarise(avg = mean(value))

先分组group_by(year,x)

X	year	Value
A	2010	1
A	2010	4
B	2010	3
C	2010	4
C	2010	3
A	2011	3
A	2011	8
B	2011	5
C	2011	2
C	2011	9

后计算df_group2

year	X	avg
2010	A	2.5
2010	B	3.0
2010	C	3.5
2011	A	5.5
2011	B	5.0
2011	C	5.5

多步操作连接符%>%

dplyr包还新引进了一个操作符，%>%，使用时把数据集名作为开头，然后依次对此数据进行多步操作。这种运算符的编写方式使得编程者可以按数据处理时的思路写代码，一步一步操作不断叠加，在程序上就可以非常清晰的体现数据处理的步骤与背后的逻辑。

数据的基本操作包package

base包

base包是安装R语言时会自带的包，已经包含一些数据框基本操作的函数，比如rbind, cbind等函数。

dplyr包

dplyr包是 Hadley Wickham (ggplot2包的作者，被称作“一个改变R的人”)的杰作，并自称 a grammar of data manipulation，他将原本plyr 包中的ddply()等函数进一步分离强化，专注接受dataframe对象，大幅提高了速度，并且提供了更稳健的与其它数据库对象间的接口。

tidyr包

tidyr包往往与dplyr包结合使用，目前渐有取代reshape2包之势，是值得关注的R包。在tidyr包中，有四个常用的函数，分别是：gather()：宽数据转换为长数据；spread()：长数据转换为宽数据；unite()：多列合并为一列；separate()：将一列分离为多列。

reshape2包

reshape2包是由Hadley Wickham开发的用于数据重构的包，其主要功能函数为melt、cast，实现了长数据和宽数据之间的转换，包中还包含其它函数和数据集。

install.packages('dplyr') #包package的安装

library(dplyr) #包package的导入，包里面的函数可直接使用

dplyr::select #使用包里面的特定某个函数

?? select #可以实现对某个函数功能的检索

张杰：微信公众号-EasyCharts



欢迎关注